

ME315 - Lab02

Nome: Elisa Guimarães Barbosa

RA 277146

Carregando bibliotecas

```
library(readr)
library(dplyr)
```

Anexando pacote: 'dplyr'

Os seguintes objetos são mascarados por 'package:stats':

`filter`, `lag`

Os seguintes objetos são mascarados por 'package:base':

`intersect`, `setdiff`, `setequal`, `union`

```
library(ggplot2)
```

```
library(ggcal)
```

01) Quais são as estatísticas suficientes para a determinação do percentual de vôos atrasados na chegada (`ARRIVAL_DELAY > 10`)

Resposta: Para calcular o percentual de voos com atraso na chegada (`arrive_delay > 10`), basta guardar dois numeros por grupo: `n` = numero de voos validos (sem NA) naquele grupo, `n_atraso` = numero de voos atrasados (`arrival_dealy > 10`). Esses dois valores sao “aditivos”: posso somar entre lotes e só no final dividir `n_atraso / n` para obter o percentual.

02)

```

getStats <- function(input, pos) {
  input %>%
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%
    filter(!is.na(ARRIVAL_DELAY)) %>%
    group_by(YEAR, MONTH, DAY, AIRLINE) %>%
    summarise(
      n          = n(),
      n_atraso   = sum(ARRIVAL_DELAY > 10),
      .groups    = "drop"
    )
}

```

03)

```

stats_lotes <- read_csv_chunked(
  file      = "flights.csv",          # <- caminho do seu arquivo aqui
  callback  = DataFrameCallback$new(getStats),
  chunk_size = 100000,
  col_types = cols_only(
    YEAR      = col_integer(),
    MONTH     = col_integer(),
    DAY       = col_integer(),
    AIRLINE   = col_character(),
    ARRIVAL_DELAY = col_double()
  )
)

```

04)

```

computeStats <- function(stats) {
  stats %>%
    group_by(YEAR, MONTH, DAY, AIRLINE) %>%
    summarise(
      n          = sum(n),
      n_atraso   = sum(n_atraso),
      .groups    = "drop"
    ) %>%
    mutate(
      Data = as.Date(paste(YEAR, MONTH, DAY, sep = "-")),
      Perc = n_atraso / n,
      Cia  = AIRLINE
    )
}

```

```

    ) %>%
    select(Cia, Data, Perc)
  }

resultado <- computeStats(stats_lotes)

```

05)

```

pal <- scale_fill_gradient(low = "#4575b4", high = "#d73027")


baseCalendario <- function(stats, cia) {
  sub <- stats %>% filter(Cia == cia)
  ggcal(sub$Data, sub$Perc)
}

cAA <- baseCalendario(resultado, "AA")
cDL <- baseCalendario(resultado, "DL")
cUA <- baseCalendario(resultado, "UA")
cUS <- baseCalendario(resultado, "US")

cAA + pal + ggtitle("American Airlines - % de atrasos na chegada (2015)")


```

American Airlines – % de atrasos na chegada (2015)




```
cDL + pal + ggtitle("Delta Airlines - % de atrasos na chegada (2015)")
```

Delta Airlines – % de atrasos na chegada (2015)




```
cUA + pal + ggtitle("United Airlines - % de atrasos na chegada (2015)")
```

United Airlines – % de atrasos na chegada (2015)



```
cUS + pal + ggtitle("US Airways - % de atrasos na chegada (2015)")
```

US Airways – % de atrasos na chegada (2015)



```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-08-24 21:06:06 -03"
```